

ΕΡΓΑΣΙΑ ΣΤΟ ΜΑΘΗΜΑ
ΥΠΟΛΟΓΙΣΤΙΚΗ ΝΟΗΜΟΣΥΝΗ – ΑΣΑΦΗ ΣΥΣΤΗΜΑΤΑ

**Επίλυση Προβλήματος Παλινδρόμησης με
Χρήση Μοντέλων TSK**

Καθηγητής: Θεοχάρης Ι.
Όνομα: Στουγιάννου Ελισάβετ

Πίνακας Περιεχομένων

1. Εισαγωγή

2. Μέρος 1: Εφαρμογή στο Airfoil Self-Noise Dataset

- 2.1 Περιγραφή Dataset & Διαχωρισμός Δεδομένων
- 2.2 Αρχιτεκτονική & Εκπαίδευση Μοντέλων TSK
- 2.3 Συναρτήσεις Συμμετοχής
- 2.4 Καμπύλες Μάθησης (Learning Curves)
- 2.5 Διαγράμματα Σφαλμάτων Πρόβλεψης
- 2.6 Αξιολόγηση & Σύγκριση Μοντέλων

3. Μέρος 2: Εφαρμογή στο Superconductivity Dataset

- 3.1 Περιγραφή Dataset & Προεπεξεργασία
- 3.2 Επιλογή Χαρακτηριστικών (ReliefF)
- 3.3 Grid Search & 5-fold Cross Validation
- 3.4 Αποτελέσματα Grid Search
- 3.5 Τελικό Μοντέλο TSK
- 3.6 Σύγκριση SC vs Grid Partitioning

4. Συμπεράσματα

1. Εισαγωγή

Η παρούσα εργασία πραγματεύεται την εφαρμογή ασαφών νευρωνικών μοντέλων τύπου TSK (Takagi-Sugeno-Kang) στο πρόβλημα της παλινδρόμησης, δηλαδή

της εκτίμησης μιας συνεχούς μεταβλητής-στόχου από ένα σύνολο εισόδων. Τα μοντέλα TSK αποτελούν ισχυρό εργαλείο μοντελοποίησης, καθώς συνδυάζουν την ερμηνευσιμότητα των ασαφών συστημάτων συμπερασμού με την προσαρμοστικότητα των νευρωνικών δικτύων, μέσω της υβριδικής μεθόδου εκπαίδευσης (backpropagation + Least Squares).

Η εργασία χωρίζεται σε δύο μέρη. Στο πρώτο μέρος χρησιμοποιείται το **Airfoil Self-Noise dataset** για μια πρώτη εξερεύνηση της εκπαίδευσης και αξιολόγησης TSK μοντέλων με διαφορετικές παραμέτρους (αριθμός συναρτήσεων συμμετοχής, τύπος εξόδου). Στο δεύτερο μέρος αντιμετωπίζεται το πρόβλημα της υψηλής διαστασιμότητας με το **Superconductivity dataset**, αξιοποιώντας τεχνικές επιλογής χαρακτηριστικών (ReliefF), ομαδοποίησης με Subtractive Clustering και βελτιστοποίησης παραμέτρων μέσω Grid Search και 5-fold διασταυρωμένης επικύρωσης.

2. Μέρος 1: Εφαρμογή στο Airfoil Self-Noise Dataset

2.1 Περιγραφή Dataset & Διαχωρισμός Δεδομένων

Το Airfoil Self-Noise dataset προέρχεται από το UCI Machine Learning Repository και περιέχει 1.503 δείγματα, καθένα από τα οποία περιγράφεται από 5 χαρακτηριστικά εισόδου: Frequency (Hz), Angle of Attack (deg), Chord Length (m), Free Stream Velocity (m/s) και Suction Side Displacement Thickness (m). Η μεταβλητή-στόχος είναι το Scaled Sound Pressure Level (dB), που αποτελεί μέτρο του αεροακουστικού θορύβου που παράγεται από αεροτομές σε διάφορες συνθήκες ροής.

Τα δεδομένα διαχωρίστηκαν τυχαία (με σταθερό seed rng(42) για αναπαραγωγιμότητα) σε τρία μη επικαλυπτόμενα υποσύνολα:

Σύνολο εκπαίδευσης (Dtrn): **902 δείγματα (60%)** — χρησιμοποιήθηκε για την εκπαίδευση των παραμέτρων κάθε μοντέλου.

Σύνολο επικύρωσης (Dval): **301 δείγματα (20%)** — χρησιμοποιήθηκε για early stopping και αποφυγή υπερεκπαίδευσης.

Σύνολο ελέγχου (Dchk): **300 δείγματα (20%)** — χρησιμοποιήθηκε αποκλειστικά για την τελική αξιολόγηση κάθε μοντέλου.

Σε κάθε περίπτωση, ως τελικό μοντέλο επιλέχθηκε εκείνο που αντιστοιχεί στο ελάχιστο validation error (best epoch) κατά τη διάρκεια της εκπαίδευσης.

2.2 Αρχιτεκτονική & Εκπαίδευση Μοντέλων TSK

Εκπαιδεύτηκαν 4 μοντέλα TSK με διαφορετικές παραμέτρους, σύμφωνα με τον Πίνακα 1. Όλα τα μοντέλα χρησιμοποίησαν Grid Partitioning για τη διαμέριση του χώρου εισόδου, bell-shaped (gbellmf) συναρτήσεις συμμετοχής με αρχικό overlap ~0.5, και εκπαιδεύτηκαν με την υβριδική μέθοδο: backpropagation για τις παραμέτρους των συναρτήσεων συμμετοχής και Least Squares για τις παραμέτρους της εξόδου.

Πίνακας 1: Ταξινόμηση μοντέλων προς εκπαίδευση


Μοντέλο	MFs ανά είσοδο	Τύπος Εξόδου	Αρ. Κανόνων
---------	----------------	--------------	-------------

TSK_model_1	2	Singleton (constant)	$2^5 = 32$
TSK_model_2	3	Singleton (constant)	$3^5 = 243$
TSK_model_3	2	Polynomial (linear)	$2^5 = 32$
TSK_model_4	3	Polynomial (linear)	$3^5 = 243$


Η υβριδική μέθοδος εκπαίδευσης αξιοποιεί το γεγονός ότι οι παράμετροι εξόδου (συντελεστές πολυωνύμου ή σταθερά singleton) εμφανίζονται γραμμικά στην έξοδο του συστήματος, επιτρέποντας τον αποδοτικό υπολογισμό τους με Least Squares στο forward pass, ενώ οι μη-γραμμικές παράμετροι των MFs βελτιστοποιούνται με backpropagation στο backward pass. Η εκπαίδευση διήρκεσε έως 100 epochs, με early stopping βάσει του validation error.

2.3 Συναρτήσεις Συμμετοχής


Τα παρακάτω διαγράμματα απεικονίζουν τις τελικές μορφές των bell-shaped (gbellmf) συναρτήσεων συμμετοχής για κάθε μοντέλο, μετά την ολοκλήρωση της εκπαίδευσης. Κάθε διάγραμμα περιέχει τις MFs και για τις 5 εισόδους του dataset.




Σχήμα 1: TSK_model_1 — Τελικές Συναρτήσεις Συμμετοχής (2 MFs/είσοδο, Singleton)



Σχήμα 2: TSK_model_2 — Τελικές Συναρτήσεις Συμμετοχής (3 MFs/είσοδο, Singleton)



Σχήμα 3: TSK_model_3 — Τελικές Συναρτήσεις Συμμετοχής (2 MFs/είσοδο, Polynomial)




Σχήμα 4: TSK_model_4 — Τελικές Συναρτήσεις Συμμετοχής (3 MFs/είσοδο, Polynomial)

Στα μοντέλα με 2 MFs ανά είσοδο (TSK_model_1 και TSK_model_3), οι συναρτήσεις συμμετοχής μετά την εκπαίδευση καλύπτουν φυσικά τα όρια κάθε εισόδου, με τις δύο MFs να διαχωρίζουν καθαρά το χαμηλό και το υψηλό εύρος τιμών κάθε μεταβλητής. Ο βαθμός επικάλυψης παραμένει κοντά στο αρχικό ~0.5, δείχνοντας ότι η εκπαίδευση δεν οδήγησε σε εκφυλισμό των MFs.

Στα μοντέλα με 3 MFs (TSK_model_2 και TSK_model_4), η κατανομή των συναρτήσεων είναι πιο πυκνή, επιτρέποντας λεπτομερέστερη διαμέριση του χώρου εισόδου. Αξιοσημείωτη είναι η ασύμμετρη μορφή που εμφανίζουν ορισμένες MFs μετά την εκπαίδευση, π.χ. στην είσοδο x_3 (Chord Length) του TSK_model_3, υποδηλώνοντας ότι ο αλγόριθμος εντόπισε μη-ομοιόμορφη κατανομή δεδομένων στον χώρο εισόδου και προσαρμόστηκε αναλόγως.

2.4 Καμπύλες Μάθησης (Learning Curves)

Τα διαγράμματα learning curves απεικονίζουν την εξέλιξη του σφάλματος RMSE εκπαίδευσης (μπλε γραμμή) και επικύρωσης (κόκκινη διακεκομμένη) συναρτήσεων των επαναλήψεων. Το τριγωνικό σύμβολο (▼) σημειώνει το best epoch, δηλαδή την επανάληψη που αντιστοιχεί στο ελάχιστο validation error και επιλέχθηκε ως τελικό μοντέλο.



Σχήμα 5: Learning Curves — Σφάλμα $RMSE$ συναρτήσεως επαναλήψεων για τα 4 μοντέλα

Το TSK_model_1 (2 MFs, Singleton) παρουσιάζει ομαλή και μονότονη μείωση του training error, ενώ το validation error σταθεροποιείται νωρίς στο epoch 12 και παραμένει σχεδόν σταθερό για το υπόλοιπο της εκπαίδευσης. Αυτή η συμπεριφορά υποδηλώνει καλή γενίκευση χωρίς ενδείξεις υπερεκπαίδευσης.


Το TSK_model_2 (3 MFs, Singleton) εμφανίζει έντονες διακυμάνσεις στο validation error από τα πρώτα epochs, με best epoch στο 21. Η μεγάλη απόκλιση μεταξύ train και validation error, καθώς και οι διακυμάνσεις, αποτελούν ένδειξη τάσης υπερεκπαίδευσης λόγω του υπερβολικού αριθμού κανόνων (243) σε σχέση με τα διαθέσιμα training samples.

Το TSK_model_3 (2 MFs, Polynomial) παρουσιάζει την πιο ομαλή learning curve από όλα τα μοντέλα, με best epoch στο 22 και μικρή σταθερή απόκλιση μεταξύ train και validation error. Αποτελεί το βέλτιστο μοντέλο από άποψη εκπαίδευσης.


Το TSK_model_4 (3 MFs, Polynomial) αποτελεί χαρακτηριστικό παράδειγμα πλήρους κατάρρευσης λόγω υπερεκπαίδευσης. Ο αριθμός παραμέτρων του μοντέλου (1.503) ισούται με τον συνολικό αριθμό δειγμάτων του dataset, γεγονός που το MATLAB επισήμανε με σχετικό warning. Το training error παρουσιάζει χασοτική, μη συγκλίνουσα συμπεριφορά, ενώ το validation error εκτοξεύεται σε τιμές εκατοντάδων έως χιλιάδων.

2.5 Διαγράμματα Σφαλμάτων Πρόβλεψης

Τα διαγράμματα της ενότητας αυτής αξιολογούν ποιοτικά την ικανότητα πρόβλεψης κάθε μοντέλου στο σύνολο ελέγχου. Απεικονίζονται η σύγκριση πραγματικής εξόδου και πρόβλεψης (time-series plot) καθώς και το ιστόγραμμα κατανομής των σφαλμάτων.



Σχήμα 6: Σύγκριση πραγματικής εξόδου και πρόβλεψης για τα 4 μοντέλα (Test Set)



Σχήμα 7: Κατανομή σφαλμάτων πρόβλεψης για τα 4 μοντέλα (Test Set)

Από το Σχήμα 6, τα TSK_model_1, TSK_model_2 και TSK_model_3 παρακολουθούν ικανοποιητικά την πραγματική έξοδο, με το TSK_model_3 να επιδεικνύει την καλύτερη εφαρμογή στα δεδομένα. Το TSK_model_4 αποκλίνει

πλήρως, παράγοντας προβλέψεις που ξεπερνούν κατά πολύ τις πραγματικές τιμές (έως 2500 dB έναντι πραγματικών τιμών ~120 dB).

Τα ιστογράμματα (Σχήμα 7) επιβεβαιώνουν τα παραπάνω: τα TSK_model_1, TSK_model_2 και TSK_model_3 εμφανίζουν κατανομή σφαλμάτων κεντραρισμένη κοντά στο μηδέν, με εύρος ± 15 dB. Το TSK_model_3 έχει την πιο συμμετρική και συμπαγή κατανομή, ενώ το TSK_model_4 παρουσιάζει σφάλματα που εκτείνονται έως -2500, υποδηλώνοντας πλήρη αποτυχία γενίκευσης.

2.6 Αξιολόγηση & Σύγκριση Μοντέλων

Ο Πίνακας 2 παρουσιάζει τους δείκτες απόδοσης RMSE, NMSE, NDEI και R^2 για τα 4 μοντέλα στο σύνολο ελέγχου. Με πράσινο χρώμα επισημαίνεται το βέλτιστο μοντέλο και με κόκκινο το χειρότερο.

Πίνακας 2: Δείκτες απόδοσης στο Test Set

Μοντέλο	RMSE	NMSE	NDEI	R^2
TSK_model_1	4.7739	0.4515	0.6719	0.5485
TSK_model_2	4.8077	0.4579	0.6767	0.5421
TSK_model_3 ✓	3.4831	0.2403	0.4903	0.7597
TSK_model_4	155.715	480.351	21.917	-479.351

Επίδραση τύπου εξόδου (Singleton vs Polynomial): Η σύγκριση μοντέλων με ίδιο αριθμό MFs αναδεικνύει καθαρά την υπεροχή της πολυωνυμικής εξόδου. Το TSK_model_3 (2 MFs, Polynomial) υπερτερεί σαφώς έναντι του TSK_model_1 (2 MFs, Singleton), με RMSE 3.48 έναντι 4.77 και R^2 0.76 έναντι 0.55, δηλαδή βελτίωση 27% στο RMSE και 38% στο R^2 . Η πολυωνυμική έξοδος επιτρέπει σε κάθε κανόνα να προσαρμόζει τοπικά μια γραμμική συνάρτηση των εισόδων αντί για μια σταθερή τιμή, οδηγώντας σε πολύ καλύτερη προσέγγιση της μη-γραμμικής συνάρτησης.

Επίδραση αριθμού MFs (2 vs 3): Στα Singleton μοντέλα, η αύξηση από 2 σε 3 MFs (TSK_model_1 → TSK_model_2) δεν βελτίωσε την απόδοση — το RMSE αυξήθηκε ελαφρά από 4.77 σε 4.81. Η αύξηση του αριθμού κανόνων από 32 σε

243 χωρίς αντίστοιχη αύξηση των training data ευνοεί την υπερεκπαίδευση, όπως επιβεβαιώνουν και οι learning curves.

Υπερεκπαίδευση στο TSK_model_4: Το TSK_model_4 αποτελεί χαρακτηριστικό παράδειγμα πλήρους κατάρρευσης λόγω υπερπαραμετροποίησης. Με 243 κανόνες και πολυωνυμική έξοδο, ο συνολικός αριθμός παραμέτρων φτάνει τις 1.503, ίσος με τον αριθμό των συνολικών δειγμάτων του dataset. Το αποτέλεσμα είναι καταστροφικό: $RMSE = 155.7$, $R^2 = -479.4$. Αρνητικό R^2 σημαίνει ότι το μοντέλο είναι χειρότερο ακόμα και από την απλή πρόβλεψη της μέσης τιμής της εξόδου — πλήρης αποτυχία γενίκευσης.

Βέλτιστο μοντέλο: Το TSK_model_3 (2 MFs, Polynomial) αναδεικνύεται ως το βέλτιστο μοντέλο, εξηγώντας το 76% της διακύμανσης της εξόδου ($R^2=0.76$) με $RMSE=3.48$ dB και $NDEI=0.49$. Το μοντέλο αυτό επιτυγχάνει την καλύτερη ισορροπία μεταξύ πολυπλοκότητας και γενίκευσης για το συγκεκριμένο dataset.

3. Μέρος 2: Εφαρμογή στο Superconductivity Dataset

3.1 Περιγραφή Dataset & Προεπεξεργασία

Το Superconductivity dataset προέρχεται από το UCI Machine Learning Repository και περιέχει 21.263 δείγματα, καθένα από τα οποία περιγράφεται από 81 χαρακτηριστικά που αφορούν φυσικοχημικές ιδιότητες υπεραγώγιμων υλικών. Η μεταβλητή-στόχος είναι η κρίσιμη θερμοκρασία (critical temperature) σε Kelvin, κάτω από την οποία το υλικό παρουσιάζει μηδενική ηλεκτρική αντίσταση.

Πριν την εκπαίδευση εφαρμόστηκαν τα εξής βήματα προεπεξεργασίας: έλεγχος για τιμές NaN/Inf (δεν εντοπίστηκαν), τυχαία ανακατάταξη των δεδομένων (shuffle με seed=42) και κανονικοποίηση όλων των χαρακτηριστικών και της εξόδου στο διάστημα [0,1] με min-max normalization. Η κανονικοποίηση είναι απαραίτητη για την ορθή λειτουργία του Subtractive Clustering και του ANFIS.

Τα δεδομένα διαχωρίστηκαν σε τρία υποσύνολα: σύνολο εκπαίδευσης (Dtrn) με 12.758 δείγματα (60%), σύνολο επικύρωσης (Dval) με 4.253 δείγματα (20%) και σύνολο ελέγχου (Dchk) με 4.252 δείγματα (20%).

3.2 Επιλογή Χαρακτηριστικών (ReliefF)

Λόγω του υψηλού αριθμού εισόδων (81 features), η απευθείας εφαρμογή ενός TSK μοντέλου με Grid Partitioning θα οδηγούσε σε εκθετική έκρηξη κανόνων (π.χ. με 2 MFs ανά είσοδο: 2^{81} κανόνες). Για τον λόγο αυτό εφαρμόστηκε επιλογή χαρακτηριστικών με τον αλγόριθμο ReliefF, ο οποίος κατατάσσει τα features κατά φθίνουσα σειρά συνάφειας με τη μεταβλητή-στόχο, εκτιμώντας τη συνεισφορά κάθε χαρακτηριστικού βάσει των αποστάσεών του από τα πλησιέστερα δείγματα.

Ο αλγόριθμος εκτελέστηκε στο σύνολο εκπαίδευσης και παρήγαγε μια ταξινομημένη λίστα των 81 χαρακτηριστικών. Τα top-12 features που επιλέχθηκαν τελικά (indices: 66, 63, 31, 1, 13, 15, 23, 37, 76, 81, 16, 69) αντιστοιχούν στις μεταβλητές με τη μεγαλύτερη στατιστική συσχέτιση με την κρίσιμη θερμοκρασία, μειώνοντας τη διαστασιμότητα κατά ~85% (από 81 σε 12 features).

3.3 Grid Search & 5-fold Cross Validation


Το μοντέλο έχει δύο ελεύθερες παραμέτρους: τον αριθμό των επιλεγμένων features και την ακτίνα cluster r_a του Subtractive Clustering, που καθορίζει έμμεσα τον αριθμό των IF-THEN κανόνων. Για την επιλογή των βέλτιστων τιμών εφαρμόστηκε Grid Search με τους εξής συνδυασμούς παραμέτρων:

Παράμετρος	Τιμές που εξετάστηκαν
Αριθμός features	4, 6, 8, 10, 12
Ακτίνα cluster r_a	0.3, 0.5, 0.7, 0.9


Για κάθε έναν από τους 20 συνδυασμούς (5×4), εκτελέστηκε 5-fold Cross Validation στο σύνολο εκπαίδευσης: τα δεδομένα χωρίστηκαν σε 5 ισόποσα folds, εκπαιδεύοντας ένα TSK μοντέλο με Subtractive Clustering σε κάθε fold και αξιολογώντας το στο υπόλοιπο 20%. Το μέσο RMSE των 5 folds αποτέλεσε το κριτήριο αξιολόγησης κάθε συνδυασμού.

3.4 Αποτελέσματα Grid Search


Τα αποτελέσματα του Grid Search απεικονίζονται στα παρακάτω διαγράμματα: το heatmap των CV RMSE τιμών, η καμπύλη RMSE συναρτήσει αριθμού features και η καμπύλη RMSE συναρτήσει αριθμού κανόνων.



Σχήμα 8: Heatmap CV RMSE — Grid Search (αριθμός features × ακτίνα cluster r_a)



Σχήμα 9: Grid Search — Mean CV RMSE συναρτήσει αριθμού features



Σχήμα 10: Grid Search — Mean CV RMSE συναρτήσει αριθμού IF-THEN κανόνων

Επίδραση αριθμού features: Το CV RMSE μειώνεται σταθερά με την αύξηση του αριθμού των επιλεγμένων features για όλες τις τιμές r_a . Η μείωση είναι ιδιαίτερα έντονη από τα 4 στα 10 features, ενώ από τα 10 στα 12 η βελτίωση γίνεται πιο ήπια. Αυτό επιβεβαιώνει ότι ο ReliefF κατατάσσει πρώτα τα πιο πληροφοριακά features, με τα επιπλέον να συνεισφέρουν μειούμενη πρόσθετη πληροφορία.


Επίδραση ακτίνας cluster r_a : Για σταθερό αριθμό features, μικρότερη ακτίνα r_a οδηγεί συστηματικά σε χαμηλότερο CV RMSE. Το $r_a=0.3$ παράγει τους περισσότερους κανόνες (12-16), επιτρέποντας λεπτομερέστερη διαμέριση του

χώρου εισόδου. Μεγαλύτερες ακτίνες (0.7, 0.9) παράγουν λιγότερους κανόνες (2-4) και εμφανώς υψηλότερο σφάλμα.

Βέλτιστες παράμετροι: Ο βέλτιστος συνδυασμός που προέκυψε από το Grid Search είναι 12 features και $\alpha=0.3$, με ελάχιστο CV RMSE = 0.0769.


3.5 Τελικό Μοντέλο TSK

Το τελικό μοντέλο εκπαιδεύτηκε με τις βέλτιστες παραμέτρους (12 features, $\alpha=0.3$) χρησιμοποιώντας Subtractive Clustering για τη δημιουργία 16 IF-THEN κανόνων και υβριδική μέθοδο για 100 epochs. Το best epoch εντοπίστηκε στο epoch 100.




Σχήμα 11: Learning Curve τελικού μοντέλου — RMSE συναρτήσει επαναλήψεων

Η learning curve παρουσιάζει ομαλή και μονότονη μείωση τόσο του training όσο και του validation error, χωρίς ενδείξεις υπερεκπαίδευσης. Το γεγονός ότι το best epoch είναι το 100 υποδηλώνει ότι το μοντέλο δεν έχει υπερεκπαιδευτεί και θα μπορούσε να βελτιωθεί περαιτέρω με περισσότερες επαναλήψεις.



Σχήμα 12: Τελικό μοντέλο — Πραγματικές τιμές vs Προβλέψεις & Scatter Plot (Test Set)

Το scatter plot ($R^2=0.81$) δείχνει ότι τα σημεία ακολουθούν σε γενικές γραμμές την ιδανική διαγώνιο $y=x$. Παρατηρείται μεγαλύτερη διασπορά στις υψηλές τιμές, γεγονός τυπικό για datasets με ανισοκατανομή όπου τα ακραία δείγματα αντιπροσωπεύονται λιγότερο στα training data.



Σχήμα 13: Συναρτήσεις συμμετοχής — Αρχική & Τελική μορφή για τις 3 πρώτες εισόδους

Συγκρίνοντας αρχική και τελική μορφή των MFs, παρατηρείται ότι μετά την εκπαίδευση οι συναρτήσεις αναδιατάσσονται ώστε να καλύπτουν πυκνότερα τις περιοχές του χώρου εισόδου όπου συγκεντρώνονται τα δεδομένα. Για την Input 2, η αρχική κατανομή ήταν ιδιαίτερα ανισόρροπη, ενώ μετά την εκπαίδευση είναι πιο ισορροπημένη.

Πίνακας 3: Δείκτες απόδοσης τελικού μοντέλου (Test Set)

RMSE	NMSE	NDEI	R ²
0.0803	0.1903	0.4362	0.8097

Το τελικό μοντέλο επιτυγχάνει $R^2=0.81$, εξηγώντας το 81% της διακύμανσης της κρίσιμης θερμοκρασίας — ικανοποιητική απόδοση για dataset υψηλής διαστασιμότητας με 21.263 δείγματα και 81 αρχικά features. Το $NDEI=0.44$ δείχνει ότι το τυπικό σφάλμα είναι περίπου το 44% της τυπικής απόκλισης της εξόδου.

3.6 Σύγκριση SC vs Grid Partitioning

Ένα από τα κεντρικά ερωτήματα της εργασίας είναι η σύγκριση του αριθμού κανόνων που προκύπτει από το Subtractive Clustering έναντι του κλασικού Grid Partitioning για τον ίδιο αριθμό εισόδων (12 features).

Πίνακας 4: Σύγκριση αριθμού IF-THEN κανόνων

Μέθοδος	Αριθμός Κανόνων	Σχόλιο
Subtractive Clustering ($\alpha=0.3$)	16	Βέλτιστο ✓
Grid Partitioning (2 MFs/είσοδο)	$2^{12} = 4.096$	256× περισσότεροι
Grid Partitioning (3 MFs/είσοδο)	$3^{12} = 531.441$	Μη εφικτό

Με μόλις 16 κανόνες το μοντέλο επιτυγχάνει $R^2=0.81$, ενώ το αντίστοιχο Grid Partitioning με 2 MFs θα απαιτούσε 4.096 κανόνες — 256 φορές περισσότερους — καθιστώντας την εκπαίδευση υπολογιστικά απαγορευτική. Η έκδοση με 3 MFs (531.441 κανόνες) είναι πρακτικά ανέφικτη.

Το Subtractive Clustering, αντί να διαμερίζει ομοιόμορφα ολόκληρο τον χώρο εισόδου, εντοπίζει τα πραγματικά clusters των δεδομένων και δημιουργεί κανόνες

μόνο εκεί όπου η πληροφορία το δικαιολογεί. Αυτή η data-driven προσέγγιση είναι η ουσία της αποτελεσματικότητάς της σε dataset υψηλής διαστασιμότητας, επιτρέποντας αποδοτική μοντελοποίηση με ελάχιστους κανόνες και χωρίς υπερεκπαίδευση.

4. Συμπεράσματα

Στην παρούσα εργασία διερευνήθηκε η ικανότητα των μοντέλων TSK να μοντελοποιούν πολυμεταβλητές μη-γραμμικές συναρτήσεις, μέσω δύο διαφορετικών datasets. Τα βασικά συμπεράσματα που προκύπτουν συνοψίζονται παρακάτω.

Από το Μέρος 1 (Airfoil Self-Noise dataset):

- Ο τύπος εξόδου αποδείχθηκε η σημαντικότερη παράμετρος σχεδιασμού. Η πολυωνυμική (linear) έξοδος υπερτερεί σαφώς της Singleton σε όλες τις μετρικές, με βελτίωση ~27% στο RMSE και ~38% στο R^2 για τον ίδιο αριθμό MFs.
- Η αύξηση του αριθμού MFs από 2 σε 3 δεν οδήγησε απαραίτητα σε βελτίωση. Αντίθετα, για τα Singleton μοντέλα η απόδοση παρέμεινε σχεδόν αμετάβλητη, ενώ για τα Polynomial οδήγησε σε καταστροφική υπερεκπαίδευση (TSK_model_4).
- Η υπερεκπαίδευση εμφανίζεται όταν ο αριθμός παραμέτρων του μοντέλου πλησιάζει ή υπερβαίνει τον αριθμό των training samples. Το TSK_model_4 με 1.503 παραμέτρους για 902 training samples κατέρρευσε πλήρως ($R^2 = -479$).
- Το βέλτιστο μοντέλο για το Airfoil dataset είναι το TSK_model_3 (2 MFs, Polynomial) με RMSE=3.48 dB και $R^2=0.76$.

Από το Μέρος 2 (Superconductivity dataset):

- Η επιλογή χαρακτηριστικών με ReliefF επέτρεψε τη δραστική μείωση της διαστασιμότητας από 81 σε 12 features (~85%) διατηρώντας την πιο πληροφοριακή πληροφορία για την πρόβλεψη της κρίσιμης θερμοκρασίας.
- Το CV RMSE μειώνεται με την αύξηση του αριθμού features και με τη μείωση της ακτίνας α . Οι βέλτιστες παράμετροι (12 features, $\alpha=0.3$) επιλέχθηκαν μέσω Grid Search με 5-fold Cross Validation, αποφεύγοντας υποκειμενικές επιλογές.
- Το Subtractive Clustering αποδείχθηκε εξαιρετικά αποδοτικό για υψηλοδιάστατα προβλήματα: με μόλις 16 κανόνες επιτεύχθηκε $R^2=0.81$, έναντι 4.096 ή 531.441 κανόνων που θα απαιτούσε το Grid Partitioning — μείωση πολυπλοκότητας κατά 256 έως 33.215 φορές.
- Το τελικό μοντέλο εξηγεί το 81% της διακύμανσης της κρίσιμης θερμοκρασίας ($R^2=0.81$, RMSE=0.08 σε κανονικοποιημένη κλίμακα), επιδεικνύοντας ικανοποιητική απόδοση για dataset υψηλής διαστασιμότητας με 21.263 δείγματα.

Συνολικά, η εργασία ανέδειξε τη σημασία της ορθής επιλογής παραμέτρων στα μοντέλα TSK: ο τύπος εξόδου, ο αριθμός MFs, η μέθοδος διαμέρισης του χώρου εισόδου και ο αριθμός των features επηρεάζουν καθοριστικά την τελική απόδοση. Η χρήση validation set για early stopping, Grid Search για βελτιστοποίηση παραμέτρων και Subtractive Clustering για αποφυγή της εκθετικής έκρηξης κανόνων αποτελούν απαραίτητα εργαλεία για την αποτελεσματική εφαρμογή TSK μοντέλων σε πραγματικά προβλήματα παλινδρόμησης.