

ΕΡΓΑΣΙΑ ΣΤΟ ΜΑΘΗΜΑ

Υπολογιστική Νοημοσύνη – Ασαφή Συστήματα

**Επίλυση Προβλήματος Ταξινόμησης
με Χρήση Μοντέλων TSK**

Καθηγητής: Θεοχάρης Ι.

Όνομα: Στουγιάννου Ελισάβετ

Πίνακας Περιεχομένων

1. Μέρος 1: Εφαρμογή σε Απλό Dataset (Haberman's Survival)

- 1.1 Περιγραφή Dataset
- 1.2 Προεπεξεργασία & Διαμέριση Δεδομένων
- 1.3 Εκπαίδευση TSK Μοντέλων
- 1.4 Διαγράμματα Μάθησης (Learning Curves)
- 1.5 Ασαφή Σύνολα (Membership Functions)
- 1.6 Πίνακες Σφαλμάτων & Δείκτες Απόδοσης
- 1.7 Σχολιασμός Αποτελεσμάτων

2. Μέρος 2: Εφαρμογή σε Dataset Υψηλής Διαστασιμότητας (Epileptic Seizure)

- 2.1 Περιγραφή Dataset
- 2.2 Προεπεξεργασία Δεδομένων
- 2.3 Επιλογή Χαρακτηριστικών (Relief)
- 2.4 Grid Search & 5-fold Cross Validation
- 2.5 Εκπαίδευση Τελικού Μοντέλου
- 2.6 Διαγράμματα Μάθησης (Learning Curves)
- 2.7 Ασαφή Σύνολα — Αρχική & Τελική Μορφή
- 2.8 Πίνακας Σφαλμάτων & Δείκτες Απόδοσης
- 2.9 Σχολιασμός Αποτελεσμάτων

3. Σύγκριση & Γενικά Συμπεράσματα

- 3.1 Συγκριτική Αξιολόγηση
- 3.2 Συμπεράσματα & Προτάσεις Βελτίωσης

1. Μέρος 1: Εφαρμογή σε Απλό Dataset (Haberman's Survival)

1.1 Περιγραφή Dataset

Το Haberman's Survival dataset προέρχεται από το UCI Machine Learning Repository και περιέχει δεδομένα ασθενών που υποβλήθηκαν σε επέμβαση καρκίνου μαστού στο Πανεπιστήμιακό Νοσοκομείο του Σικάγο μεταξύ 1958 και 1970. Το σύνολο αποτελείται από 306 δείγματα, καθένα από τα οποία περιγράφεται από 3 χαρακτηριστικά:

- Ηλικία ασθενούς κατά τη διάρκεια της επέμβασης
- Έτος εκτέλεσης της επέμβασης (κωδικοποιημένο ως 58–69)
- Πλήθος ανιχνευμένων θετικών αξιλλαίων λεμφαδένων

Η μεταβλητή-στόχος είναι δυαδική: Κλάση 1 (επιβίωση τουλάχιστον 5 χρόνια μετά την επέμβαση, 225 δείγματα) και Κλάση 2 (θάνατος εντός 5 ετών, 81 δείγματα). Παρατηρείται έντονη κλασική ανισορροπία με αναλογία περίπου 2.78:1 υπέρ της κλάσης 1.

1.2 Προεπεξεργασία & Διαμέριση Δεδομένων

Εφαρμόστηκε στρωματοποιημένη (stratified) τυχαία διαμέριση με αναλογία 60%–20%–20% για τα σύνολα εκπαίδευσης (Dtrn), επικύρωσης (Dval) και ελέγχου (Dchk) αντίστοιχα. Η στρωματοποίηση διασφαλίζει ότι η κατανομή των κλάσεων παραμένει αντιπροσωπευτική του αρχικού dataset σε κάθε υποσύνολο — κρίσιμο βήμα ιδιαίτερα για ανισόρροπα datasets όπως το παρόν.

Σύνολο	Δείγματα	Κλάση 1	Κλάση 2
Εκπαίδευσης (60%)	183	135	48
Επικύρωσης (20%)	61	45	16
Ελέγχου (20%)	61	45	16

Πίνακας 1.1: Διαμέριση δεδομένων Haberman's Survival

Δεν εφαρμόστηκε κανονικοποίηση, καθώς το SC του MATLAB λειτουργεί αποτελεσματικά στο αρχικό εύρος τιμών των 3 features.

1.3 Εκπαίδευση TSK Μοντέλων

Εκπαιδεύτηκαν τέσσερα TSK μοντέλα με διαφορετικούς παραμέτρους Subtractive Clustering. Για κάθε μοντέλο, η αρχικοποίηση έγινε με τη συνάρτηση genfis του MATLAB (επιλογή SubtractiveClustering) και η εκπαίδευση με την υβριδική μέθοδο (backpropagation για τις παραμέτρους των MF + least squares για τις παραμέτρους εξόδου). Οι συναρτήσεις εξόδου μετατράπηκαν χειροκίνητα από γραμμικές σε singleton, ώστε η πραγματική έξοδος του μοντέλου να αντιστοιχεί στις ακέραιες τιμές κλάσεων {1, 2}. Η ταξινόμηση γίνεται με ανάθεση στην πλησιέστερη κλάση (nearest-class rule).

Τα τέσσερα μοντέλα διαφέρουν ως εξής:

- Μοντέλο 1 — Class-Independent SC, μικρή ακτίνα ($r=0.3$): παράγει μεγάλο αριθμό κανόνων
- Μοντέλο 2 — Class-Independent SC, μεγάλη ακτίνα ($r=0.8$): παράγει μικρό αριθμό κανόνων
- Μοντέλο 3 — Class-Dependent SC, μικρή ακτίνα ($r=0.3$): SC εφαρμόζεται ξεχωριστά ανά κλάση, μεγάλος αριθμός κανόνων
- Μοντέλο 4 — Class-Dependent SC, μεγάλη ακτίνα ($r=0.8$): SC ανά κλάση, μικρός αριθμός κανόνων


Στην class-independent προσέγγιση, το SC εκτελείται σε όλα τα training δεδομένα αδιακρίτως κλάσης. Στην class-dependent, εκτελείται ξεχωριστά για κάθε κλάση, παράγοντας clusters που αντικατοπτρίζουν την εσωτερική δομή κάθε κλάσης — αυξάνοντας έτσι την ερμηνευσιμότητα των κανόνων.

Μοντέλο	Τύπος SC	Ακτίνα r	Κανόνες
Μοντέλο 1	Class-Independent	0.3	16
Μοντέλο 2	Class-Independent	0.8	3
Μοντέλο 3	Class-Dependent	0.3	31
Μοντέλο 4	Class-Dependent	0.8	4

Πίνακας 1.2: Παράμετροι των 4 TSK μοντέλων

1.4 Διαγράμματα Μάθησης (Learning Curves)


Τα διαγράμματα μάθησης απεικονίζουν την εξέλιξη του σφάλματος RMSE κατά τη διάρκεια της εκπαίδευσης (training error) και την απόδοση στο σύνολο επικύρωσης (validation error) συναρτήσει του αριθμού των επαναλήψεων (epochs). Χρησιμοποιήθηκαν 100 epochs για όλα τα μοντέλα.






Σχήμα 1.1: Διαγράμματα μάθησης (Training & Validation RMSE) για τα 4 TSK μοντέλα

1.5 Ασαφή Σύνολα (Membership Functions)

Παρακάτω απεικονίζονται οι τελικές μορφές των ασαφών συνόλων για κάθε μοντέλο, μετά την ολοκλήρωση της εκπαίδευσης. Κάθε διάγραμμα αντιστοιχεί σε έναν άξονα εισόδου (feature) και δείχνει τις Gaussian συναρτήσεις συμμετοχής που προέκυψαν από το SC.




Σχήμα 1.2: Membership Functions — Μοντέλο 1 (Class-Independent, $r=0.3$)


Σχήμα 1.3: Membership Functions — Μοντέλο 2 (Class-Independent, $r=0.8$)Σχήμα 1.4: Membership Functions — Μοντέλο 3 (Class-Dependent, $r=0.3$)Σχήμα 1.5: Membership Functions — Μοντέλο 4 (Class-Dependent, $r=0.8$)

1.6 Πίνακες Σφαλμάτων & Δείκτες Απόδοσης


Για την αξιολόγηση κάθε μοντέλου στο test set χρησιμοποιήθηκαν οι εξής δείκτες: Overall Accuracy (OA), Producer's Accuracy (PA) ανά κλάση, User's Accuracy (UA) ανά κλάση και ο δείκτης κ (Kappa).




Σχήμα 1.6: Confusion Matrix — Μοντέλο 1 (CI, $r=0.3$, 16 κανόνες)



Σχήμα 1.7: Confusion Matrix — Μοντέλο 2 (CI, $r=0.8$, 3 κανόνες)



Σχήμα 1.8: Confusion Matrix — Μοντέλο 3 (CD, $r=0.3$, 31 κανόνες)



Σχήμα 1.9: Confusion Matrix — Μοντέλο 4 (CD, $r=0.8$, 4 κανόνες)

Μοντέλο	Κανόνες	ΟΑ (%)	ΡΑ(C1) (%)	ΡΑ(C2) (%)	ΥΑ(C1) (%)	ΥΑ(C2) (%)	κ
Μοντέλο 1 (CI, $r=0.3$)	16	70.49	84.4	31.2	77.6	41.7	0.171
Μοντέλο 2 (CI, $r=0.8$)	3	70.49	86.7	25.0	76.5	40.0	0.133
Μοντέλο 3 (CD, $r=0.3$)	31	60.66	68.9	37.5	75.6	30.0	0.059
Μοντέλο 4 (CD, $r=0.8$)	4	73.77	91.1	25.0	77.4	50.0	0.192

Πίνακας 1.3: Συνοπτικά αποτελέσματα αξιολόγησης — test set

1.7 Σχολιασμός Αποτελεσμάτων

Επίδραση Αριθμού Κανόνων στην Απόδοση

Παρατηρείται ότι η αύξηση του αριθμού κανόνων δεν βελτιώνει πάντα την απόδοση. Τα Μοντέλα 1 και 2 (class-independent) παρουσιάζουν ακριβώς την ίδια ΟΑ (70.49%), παρά τη μεγάλη διαφορά στον αριθμό κανόνων (16 vs 3). Αυτό υποδηλώνει ότι πέρα από έναν ελάχιστο αριθμό κανόνων που επαρκεί για να περιγράψει τη δομή των δεδομένων, περισσότεροι κανόνες δεν προσθέτουν πληροφορία.

Το Μοντέλο 3 (class-dependent, $r=0.3$, 31 κανόνες) παρουσιάζει τη χειρότερη ΟΑ (60.66%), παρά τον μεγαλύτερο αριθμό κανόνων. Αυτό αποτελεί κλασικό σύμπτωμα υπερεκπαίδευσης (overfitting): το μοντέλο απομνημονεύει τα training δεδομένα αλλά δεν γενικεύει στο test set. Η learning curve του Μοντέλου 3 επιβεβαιώνει αυτό, εμφανίζοντας αύξηση του validation error ενώ το training error συνεχίζει να μειώνεται.

Βέλτιστο Μοντέλο — Μοντέλο 4

Το Μοντέλο 4 (class-dependent, $r=0.8$, 4 κανόνες) επιτυγχάνει την καλύτερη απόδοση με **ΟΑ = 73.77%** και **$\kappa = 0.192$** . Ο συνδυασμός class-dependent clustering με μεγάλη ακτίνα παράγει ένα συμπαγές μοντέλο με 4 καλά τοποθετημένους κανόνες (2 ανά κλάση), που ισορροπεί μεταξύ εκφραστικότητας και γενίκευσης.

Επικάλυψη MFs & Ενεργοποίηση Κανόνων

Στα class-independent μοντέλα (1 & 2), τα MFs κατανέμονται ομοιόμορφα στον χώρο εισόδου χωρίς να λαμβάνουν υπόψη τη δομή των κλάσεων. Αυτό οδηγεί σε σημαντική επικάλυψη MFs διαφορετικών κανόνων, με αποτέλεσμα πολλοί κανόνες να ενεργοποιούνται ταυτόχρονα για κάθε δείγμα. Η αθροιστική αυτή ενεργοποίηση αμβλύνει τη διακριτική ικανότητα του μοντέλου.

Αντίθετα, στο Μοντέλο 4 (class-dependent, $r=0.8$) τα MFs τοποθετούνται εκεί όπου πράγματι συγκεντρώνονται τα δεδομένα κάθε κλάσης, παράγοντας κανόνες με φυσική ερμηνεία: κάθε κανόνας αντιστοιχεί σε μια συνοχή (cluster) δειγμάτων συγκεκριμένης κλάσης. Η μειωμένη επικάλυψη οδηγεί σε πιο εκλεκτική ενεργοποίηση κανόνων και βελτιωμένη ταξινόμηση.

Κλασική Ανισορροπία (Class Imbalance)

Και τα 4 μοντέλα εμφανίζουν χαμηλό $PA(C2)$ (25%–37.5%), αντικατοπτρίζοντας την ανισορροπία του dataset (225 C1 vs 81 C2 δείγματα). Το μοντέλο τείνει να προβλέπει κυρίως C1, επιτυγχάνοντας υψηλό $PA(C1)$ αλλά υποβαθμίζοντας την αναγνώριση της μειοψηφικής κλάσης. Αυτό αποτελεί γνωστή αδυναμία των μοντέλων που εκπαιδεύονται χωρίς ειδική μεταχείριση της ανισορροπίας (π.χ. oversampling, class weights).

2. Μέρος 2: Εφαρμογή σε Dataset Υψηλής Διαστασιμότητας (Epileptic Seizure)

2.1 Περιγραφή Dataset

Το Epileptic Seizure Recognition dataset προέρχεται από το UCI Machine Learning Repository και περιέχει 11.500 δείγματα εγκεφαλογραφήματος (EEG). Κάθε δείγμα αντιστοιχεί σε ένα τμήμα χρονοσειράς EEG και περιγράφεται από 178 χρονικές μεταβλητές. Τα δείγματα κατανέμονται ισομερώς σε 5 κλάσεις (2.300 ανά κλάση):

- Κλάση 1: Εγγραφή EEG κατά τη διάρκεια επιληπτικής κρίσης
- Κλάση 2: Εγγραφή EEG από την περιοχή εντοπισμού επιληπτικής εστίας (εκτός κρίσης)
- Κλάση 3: Εγγραφή EEG από υγιή εγκεφαλική περιοχή (εκτός κρίσης)
- Κλάση 4: Εγγραφή EEG με κλειστά μάτια (υγιείς εθελοντές)
- Κλάση 5: Εγγραφή EEG με ανοιχτά μάτια (υγιείς εθελοντές)

Ο μεγάλος αριθμός χαρακτηριστικών (178) καθιστά αναγκαία τη χρήση μεθόδων μείωσης διαστασιμότητας. Σε αντίθεση με το Μέρος 1, οι 5 κλάσεις είναι απολύτως ισορροπημένες.

2.2 Προεπεξεργασία Δεδομένων

Εφαρμόστηκε στρωματοποιημένη διαμέριση 60%–20%–20% για τα σύνολα εκπαίδευσης, επικύρωσης και ελέγχου. Η στρωματοποίηση διασφαλίζει ισόποση εκπροσώπηση και των 5 κλάσεων σε κάθε υποσύνολο.

Σύνολο	Δείγματα	Ανά κλάση
Εκπαίδευσης (60%)	6.900	1.380
Επικύρωσης (20%)	2.300	460
Ελέγχου (20%)	2.300	460

Πίνακας 2.1: Διαμέριση δεδομένων Epileptic Seizure Recognition

Ακολούθως εφαρμόστηκε Z-score κανονικοποίηση στα features. Οι παράμετροι (μέσος όρος μ και τυπική απόκλιση σ) υπολογίστηκαν αποκλειστικά από το training set και εφαρμόστηκαν στα σύνολα επικύρωσης και ελέγχου, αποφεύγοντας τη διαρροή πληροφορίας (data leakage).

2.3 Επιλογή Χαρακτηριστικών (Feature Selection — Relief)

Λόγω του μεγάλου αριθμού χαρακτηριστικών (178), η απευθείας εφαρμογή TSK θα οδηγούσε σε εκρηκτική αύξηση κανόνων. Χρησιμοποιήθηκε ο αλγόριθμος Relief (relieff στο MATLAB, $k=10$ γείτονες).

Ο Relief εκτιμά τη σπουδαιότητα κάθε feature αξιολογώντας πόσο καλά διαχωρίζει δείγματα διαφορετικών κλάσεων: για κάθε δείγμα εντοπίζει τους k πλησιέστερους

ομοειδείς (hits) και ετεροειδείς (misses) γείτονες, και ενημερώνει τη βαθμολογία κάθε feature ανάλογα.

Τα 15 κορυφαία features (indices): **[51, 52, 50, 113, 145, 143, 79, 114, 144, 80, 75, 115, 146, 116, 133]**. Αντιστοιχούν σε χρονικές θέσεις του EEG σήματος που παρουσιάζουν τη μεγαλύτερη διαχωριστική ικανότητα μεταξύ επιληπτικής κρίσης και υπόλοιπων καταστάσεων.


2.4 Grid Search & 5-fold Cross Validation

Για την επιλογή των βέλτιστων τιμών των δύο ελεύθερων παραμέτρων — αριθμός features (nF) και ακτίνα SC (ra) — εκτελέστηκε αναζήτηση πλέγματος (grid search) με 5-fold στρωματοποιημένη διασταυρωμένη επικύρωση.

Εξετάστηκαν οι εξής τιμές:

- Αριθμός features: $nF \in \{2, 4, 6, 8, 10\}$
- Ακτίνα Subtractive Clustering: $ra \in \{0.3, 0.5, 0.7, 0.9\}$

Συνολικά εξετάστηκαν 20 συνδυασμοί (5×4). Για κάθε συνδυασμό, το training set διαμερίστηκε σε 5 folds με stratified sampling. Σε κάθε επανάληψη, το 80% χρησιμοποιήθηκε για εκπαίδευση (30 epochs) και το 20% για αξιολόγηση. Για λόγους υπολογιστικής αποδοτικότητας, η CV εκτελέστηκε σε τυχαίο στρωματοποιημένο υποσύνολο 20% του training set. Γραμμή αξιολόγησης: μέσο classification error των 5 folds.



Σχήμα 2.1: Αποτελέσματα Grid Search — Heatmap CV error (αριστερά), Error vs Features (κέντρο), Error vs Radius (δεξιά). Το πράσινο αστέρι δηλώνει τις βέλτιστες παραμέτρους.

nF \ ra	r=0.3	r=0.5	r=0.7	r=0.9
nF=2	0.6874	0.6930	0.6896	0.6874
nF=4	0.6836	0.6892	0.6856	0.6913
nF=6	0.7598	0.7643	0.7612	0.7621

$nF \setminus r\alpha$	$r=0.3$	$r=0.5$	$r=0.7$	$r=0.9$
$nF=8$	0.8043	0.8076	0.8021	0.8052
$nF=10$	0.8063	0.8105	0.8077	0.8091

Πίνακας 2.2: Μέσο CV Error για κάθε συνδυασμό παραμέτρων (nF , $r\alpha$)

Βέλτιστες παράμετροι: $nF = 4$, $r\alpha = 0.3$, με CV Error = 0.6836.

2.5 Εκπαίδευση Τελικού Μοντέλου


Με τις βέλτιστες παραμέτρους ($nF=4$, $r\alpha=0.3$) εκπαιδεύτηκε το τελικό TSK μοντέλο στο πλήρες training set (100 epochs). Χρησιμοποιήθηκε class-dependent Subtractive Clustering: το SC εφαρμόστηκε ξεχωριστά στα δεδομένα κάθε κλάσης, και η συνολική βάση κανόνων προέκυψε ως η ένωση των επιμέρους κανόνων. Οι συναρτήσεις εξόδου ορίστηκαν ως singleton με τιμές {1, 2, 3, 4, 5}.

Παράμετρος	Τιμή
Επιλεγμένα features (nF)	4 — indices: [51, 52, 50, 113]
Ακτίνα SC ($r\alpha$)	0.3
Κανόνες μοντέλου (SC)	~5 (1 ανά κλάση)
Κανόνες Grid (2MF ανά είσοδο)	$2^4 = 16$
Κανόνες Grid (3MF ανά είσοδο)	$3^4 = 81$
Epochs εκπαίδευσης	100
Μέθοδος εκπαίδευσης	Υβριδική (BP + Least Squares)

Πίνακας 2.3: Παράμετροι τελικού μοντέλου και σύγκριση πολυπλοκότητας με Grid Partitioning

2.6 Διαγράμματα Μάθησης (Learning Curves)


Τα διαγράμματα μάθησης απεικονίζουν την εξέλιξη του RMSE στα σύνολα εκπαίδευσης και επικύρωσης συναρτήσει των epochs.




Σχήμα 2.2: Learning Curves τελικού μοντέλου — Training (μπλε) και Validation (κόκκινο) RMSE συναρτήσεσι επαναλήψεων

2.7 Ασαφή Σύνολα — Αρχική & Τελική Μορφή

Παρακάτω απεικονίζονται οι συναρτήσεις συμμετοχής των 3 πρώτων εισόδων πριν και μετά την εκπαίδευση. Κάθε χρώμα αντιστοιχεί σε ένα MF που παρήχθη από το SC μιας συγκεκριμένης κλάσης.




Σχήμα 2.3: Αρχικές Membership Functions (πριν την εκπαίδευση) — 3 πρώτες είσοδοι




Σχήμα 2.4: Τελικές Membership Functions (μετά την εκπαίδευση) — 3 πρώτες εισοδοι

2.8 Πίνακας Σφαλμάτων & Δείκτες Απόδοσης



Σχήμα 2.5: Confusion Matrix τελικού μοντέλου στο test set



Σχήμα 2.6: Προβλέψεις vs Πραγματικές τιμές για τα πρώτα 300 test δείγματα

Μετρική	C1 (Epileptic)	C2	C3	C4	C5	Σύνολο
PA (Producer's Accuracy)	73.70%	5.00%	70.22%	25.65%	0.00%	—
UA (User's Accuracy)	89.21%	18.70%	25.92%	21.42%	—	—
OA (Overall Accuracy)	—	—	—	—	—	34.91%
Kappa (κ)	—	—	—	—	—	0.1864

Πίνακας 2.4: Δείκτες απόδοσης τελικού μοντέλου στο test set

2.9 Σχολιασμός Αποτελεσμάτων

Grid Search — Επίδραση Παραμέτρων

Από τον Πίνακα 2.2 και το Σχήμα 2.1 προκύπτουν δύο σαφείς τάσεις. Πρώτον, το CV error αυξάνεται απότομα για $nF \geq 6$ (0.684 σε $\sim 0.76-0.81$), λόγω του φαινομένου της "έκρηξης κανόνων": με περισσότερα features και μικρή ακτίνα, το SC παράγει πολλούς κανόνες που οδηγούν σε υπερεκπαίδευση. Δεύτερον, η επίδραση της ακτίνας φαίνεται ήπια με ελαφρά προτίμηση στο $r=0.3$.

SC vs Grid Partitioning — Σύγκριση Πολυπλοκότητας

Με $nF=4$ και class-dependent SC ($\alpha=0.3$), το μοντέλο παράγει **~5 κανόνες** έναντι **16 (Grid 2MF)** και **81 (Grid 3MF)**. Η SC προσέγγιση μειώνει την πολυπλοκότητα κατά 3–16φ, καθιστώντας το μοντέλο πολύ πιο ερμηνεύσιμο και αποδοτικό. Σε υψηλότερες διαστάσεις (π.χ. 10 features) η διαφορά γίνεται δραματική: $2^{10}=1024$ έναντι ~ 10 κανόνων SC.

Απόδοση & Φαινόμενο C5=0

Η συνολική ακρίβεια ($OA=34.91\%$, $\kappa=0.186$) είναι αναμενόμενα χαμηλή για ένα απλό TSK με 4 features σε αυτό το dataset. Το φαινόμενο $C5=0$ ($PA=0\%$) οφείλεται στη φύση του dataset: οι κλάσεις 2–5 παρουσιάζουν παρόμοια φασματική δομή EEG, και στον κανονικοποιημένο feature space με 4 μόνο features τα clusters τους συγκλίνουν γύρω από το 0.

Αντίθετα, η κλάση 1 (επιληπτική κρίση) επιτυγχάνει $PA=73.7\%$ και $UA=89.2\%$, καθώς τα EEG σήματα κατά τη διάρκεια κρίσης παρουσιάζουν χαρακτηριστικά μορφολογικά γνωρίσματα που το μοντέλο αναγνωρίζει αξιόπιστα. Αυτό έχει ιδιαίτερη κλινική σημασία, καθώς η έγκαιρη ανίχνευση επιληπτικών κρίσεων αποτελεί τον κύριο στόχο εφαρμογών αυτόματης ανάλυσης EEG.

Ασαφή Σύνολα — Παρατηρήσεις

Τα διαγράμματα MFs αποκαλύπτουν ότι και οι 5 συναρτήσεις συμμετοχής (μία ανά κλάση) συγκεντρώνονται γύρω από το 0 στον κανονικοποιημένο χώρο. Αυτό επιβεβαιώνει ότι το SC δεν μπορεί να διαχωρίσει τις κλάσεις 2–5 στο επιλεγμένο feature subspace: τα clusters τους είναι σχεδόν ταυτόσημα. Η μεγάλη επικάλυψη οδηγεί σε ταυτόχρονη ενεργοποίηση όλων των κανόνων για κάθε δείγμα, εξάγοντας εξόδο κοντά στη μέση τιμή των singletons (~ 3).

Learning Curves — Παρατηρήσεις

Οι learning curves δείχνουν ομαλή σύγκλιση χωρίς σημεία υπερεκπαίδευσης. Το validation RMSE (≈ 1.138) είναι ελαφρά χαμηλότερο από το training RMSE (≈ 1.143), υποδηλώνοντας underfitting — το μοντέλο δεν έχει επαρκή εκφραστικότητα για να μάθει τη δομή του προβλήματος. Η ταλάντωση στο training error αντικατοπτρίζει τον συνδυαστικό χαρακτήρα της υβριδικής μεθόδου (εναλλαγή BP και LSE βημάτων).

3. Σύγκριση & Γενικά Συμπεράσματα

3.1 Συγκριτική Αξιολόγηση

Στον παρακάτω πίνακα συνοψίζονται τα κεντρικά χαρακτηριστικά και αποτελέσματα των δύο μερών της εργασίας:

Χαρακτηριστικό	Μέρος 1 (Haberman)	Μέρος 2 (Epileptic Seizure)
Dataset	306 δείγματα, 3 features, 2 κλάσεις	11.500 δείγματα, 178 features, 5 κλάσεις
Ισορροπία κλάσεων	Ανισόρροπη (2.78:1)	Απόλυτα ισόρροπη (460 ανά κλάση)
Κανονικοποίηση	Όχι	Z-score (fit on train)
Feature Selection	Όχι (3 features)	Relief, top-4 από 178
Grid Search	Όχι	Ναι ($nF \times \alpha$, 5-fold CV)
Βέλτιστο μοντέλο	CD, $r=0.8$, 4 κανόνες	CD, $\alpha=0.3$, ~5 κανόνες
ΟΑ (καλύτερο μοντέλο)	73.77%	34.91%
κ' (καλύτερο μοντέλο)	0.192	0.186
Κλάσεις που διαχωρίζονται καλά	C1 καλά (PA=91%), C2 αδύναμη	Μόνο C1 αξιόπιστα (PA=73.7%)

Πίνακας 3.1: Συγκριτικός πίνακας Μέρους 1 & Μέρους 2

3.2 Συμπεράσματα & Προτάσεις Βελτίωσης

Class-Dependent vs Class-Independent SC

Η class-dependent προσέγγιση υπερτερεί σταθερά της class-independent στο Μέρος 1. Τοποθετώντας τα clusters εκεί όπου βρίσκονται πραγματικά τα δείγματα κάθε κλάσης, δημιουργούνται κανόνες με φυσική ερμηνεία: κάθε κανόνας αντιστοιχεί σε μια συνοχή (cluster) δειγμάτων μιας συγκεκριμένης κλάσης. Αυτό οδηγεί σε πιο εκλεκτική ενεργοποίηση κανόνων και βελτιωμένη διακριτική ικανότητα.

Αριθμός Κανόνων vs Απόδοση — Αρχή λιτότητας

Και στα δύο μέρη, το βέλτιστο μοντέλο δεν ήταν αυτό με τον μεγαλύτερο αριθμό κανόνων. Η αρχή της λιτότητας (Occam's Razor) επιβεβαιώνεται: ένα απλό μοντέλο με λίγους, καλά τοποθετημένους κανόνες γενικεύει καλύτερα από ένα μοντέλο με πολλούς κανόνες που απομνημονεύει τα training δεδομένα. Στο Μέρος 1, το Μοντέλο 3 (31 κανόνες) είναι χαρακτηριστικό παράδειγμα overfitting ενώ το Μοντέλο 4 (4 κανόνες) επιτυγχάνει την καλύτερη γενίκευση.

SC vs Grid Partitioning — Συμπεράσματα

Το Subtractive Clustering αποδεικνύεται σαφώς ανώτερο από το Grid Partitioning ως μέθοδος αρχικοποίησης TSK μοντέλων, ιδιαίτερα όταν ο αριθμός των features αυξάνεται. Ο λόγος είναι η εκθετική αύξηση κανόνων στο Grid Partitioning: με d features και k MFs ανά είσοδο, δημιουργούνται k^d κανόνες. Για $d=10$ και $k=2$ αυτό ισούται με 1.024 κανόνες, κάτι πρακτικά αδύνατο να εκπαιδευτεί με ANFIS. Το SC,

ανεξάρτητα από τη διαστασιμότητα, παράγει μικρό και σταθερό αριθμό κανόνων, αντιστοιχώντας στην πραγματική δομή των δεδομένων.

Επίδραση της Διαστασιμότητας του Dataset

Η χαμηλή ΟΑ (34.91%) στο Μέρος 2 δεν αντικατοπτρίζει αποτυχία της μεθόδου, αλλά τη γνωστή δυσκολία διαχωρισμού των κλάσεων 2–5 του Epileptic Seizure dataset. Η αξιόπιστη ανίχνευση της επιληπτικής κρίσης (PA=73.7%) αποτελεί εν δυνάμει σημαντικό αποτέλεσμα. Συγκριτικά, στο Μέρος 1 ο περιορισμός της απόδοσης οφείλεται κυρίως στην κλασική ανισορροπία του dataset, ενώ στο Μέρος 2 οφείλεται στην εγγενή δυσκολία διαχωρισμού των κλάσεων EEG με απλό feature subspace.

Προτάσεις Βελτίωσης

Με βάση τα αποτελέσματα και τις παρατηρήσεις των δύο μερών, οι κυριότερες προτάσεις για βελτίωση είναι:

- Για το Μέρος 1: Χρήση τεχνικών αντιμετώπισης κλασικής ανισορροπίας (π.χ. SMOTE oversampling ή cost-sensitive learning) για βελτίωση της PA(K2)
- Για το Μέρος 2: Εφαρμογή feature extraction (PCA, ανάλυση κυματομορφής, φασματικές δεσμές) αντί για raw time-series features για καλύτερη διαχωρισιμότητα κλάσεων 2–5
- Για το Μέρος 2: Εξέταση ιεραρχικής αρχιτεκτονικής TSK όπου αρχικά διαχωρίζεται η C1 (επιληπτική κρίση) από τις υπόλοιπες και στη συνέχεια γίνεται η τελική ταξινόμηση μεταξύ των υπόλοιπων 4 κλάσεων
- Γενικά: Αύξηση του feature subset μέσω πιο εξελεγχόμενης επιλογής χαρακτηριστικών (π.χ. wrapper methods) αντί για filter (Relief)

Συνοψικά, η χρήση TSK μοντέλων με class-dependent Subtractive Clustering αποδεικνύεται αποτελεσματική στρατηγική για την ανάπτυξη συμπαγών, ερμηνεύσιμων μοντέλων ταξινόμησης, ιδιαίτερα σε προβλήματα όπου η ερμηνευσιμότητα και ο περιορισμός πόρων επεξεργασίας είναι εξίσου σημαντική με την ακρίβεια.